Hlboké neurónové siete
Projekt č. 2

Rozpoznávanie gest tváre (RGB - 5 skupín)
Rozpoznávanie gest ruky (RGB - 4 skupiny)

AUTORI

Filip Kuruc
Marek Sýkorka

STU FEI
SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

ÚRK
Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave





Dataset Gest Tváre

EURECOM Kinect Face (RGB)

Dataset EURECOM Kinect Face

- Skladá sa z viacerých typov dát zachytávajúcich gestá tváre
  - 3DObj (.obj)
  - Depth (Hĺbkové)
    - DepthBMP (.bmp)
    - DepthKinect (.txt)
  - RGB (.bmp)

- Okrem obrazových dát obsahuje aj markery určené pre iné úlohy
  - Mark3DObj (.txt)
  - MarkDepth (.txt)
  - MarkRGB (.txt)

Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

Dataset EURECOM Kinect Face (RGB)

- Obsahuje snímky gest tváre rozdelené do deviatich kategórií



Right Profile
Pravý profil



Light On
Osvetlená tvár



Left Profile
Ľavý profil

Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

Dataset EURECOM Kinect Face (RGB)

- Obsahuje snímky gest tváre rozdelené do deviatich kategórií



Occlusion Eyes
Zatienené oči



Occlusion Mouth
Zatienené ústa

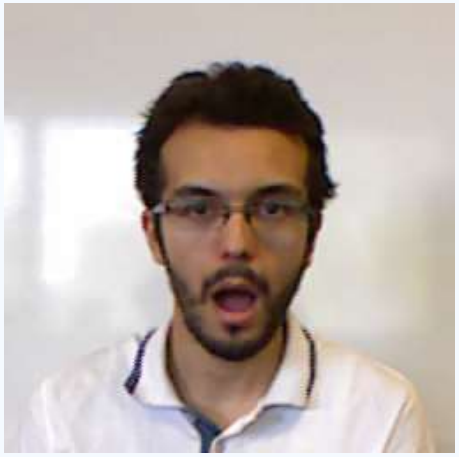


Occlusion Paper
Zatienenie papierom

Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

Dataset EURECOM Kinect Face (RGB)

- Obsahuje snímky gest tváre rozdelené do deviatich kategórií



Open Mouth
Otvorené ústa



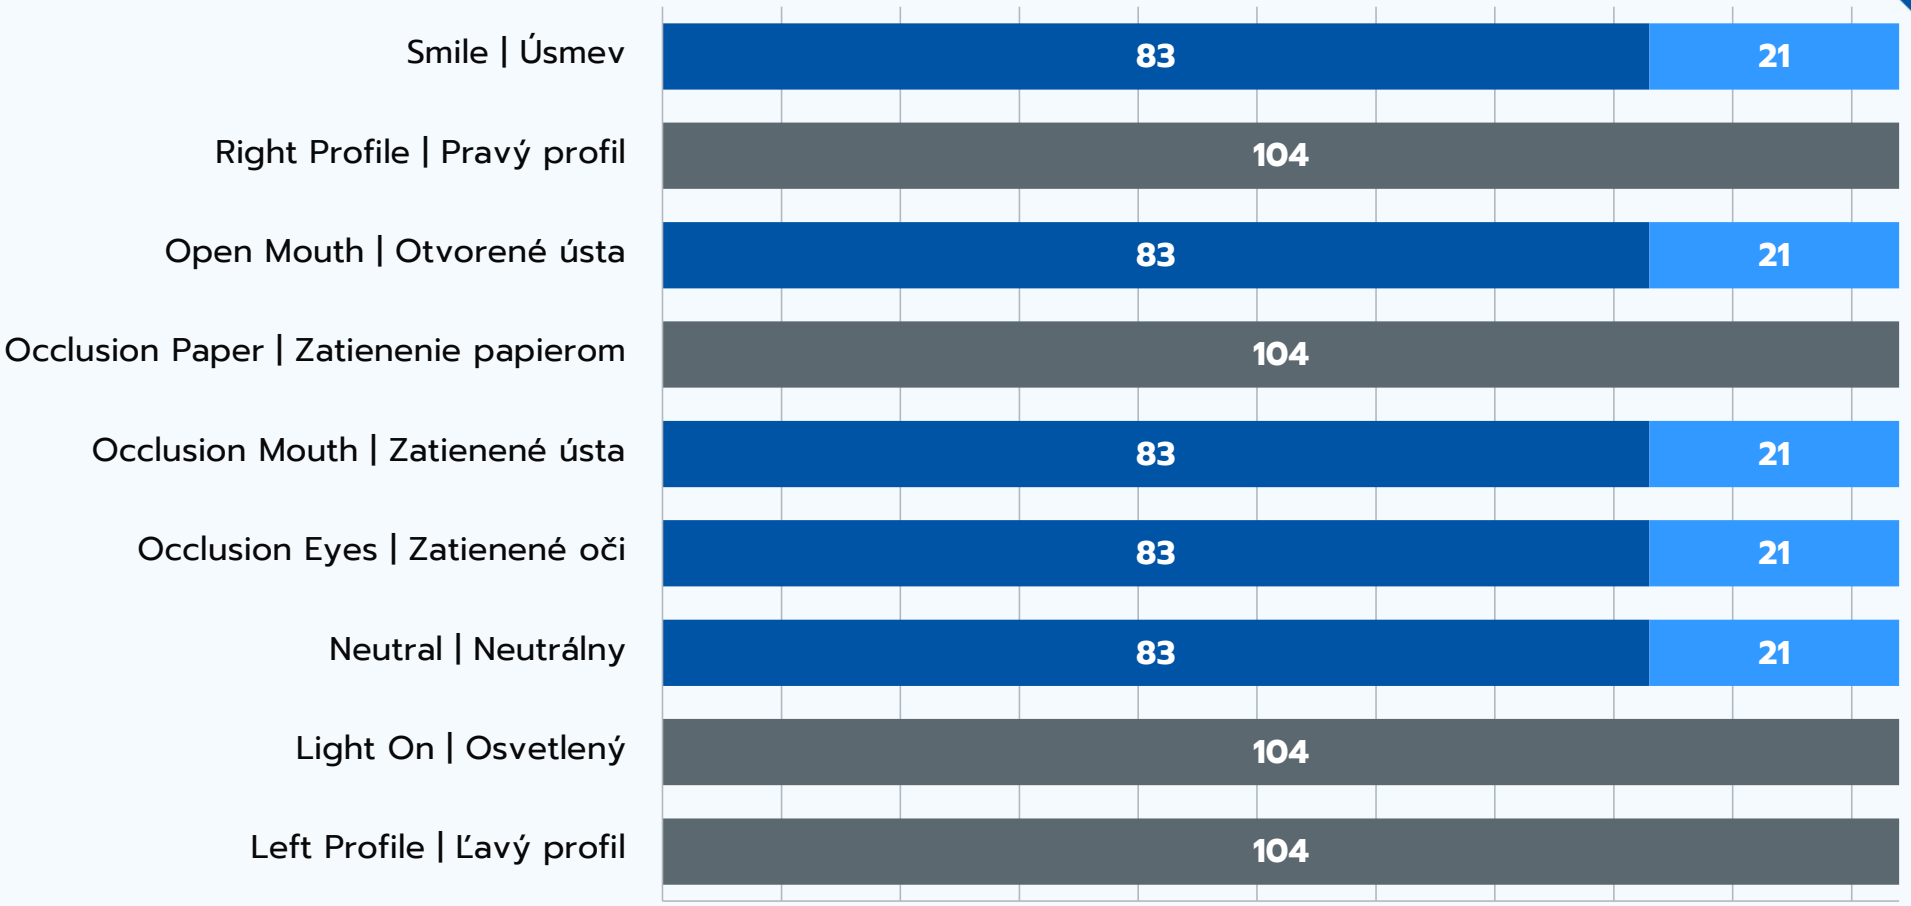
Neutral
Neutrálny



Smile
Úsmev

Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

Rozdelenie datasetu



Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave



Vlastná štruktúra CNN

EURECOM Kinect Face (RGB)

Sériová KinectCNNv2 – štruktúra

```
# 1st layer                                                    
self.layer1 = nn.Sequential(                                   [B,   3-CH, 256, 256]
    nn.Conv2d(3, 32, kernel_size=9, padding=1),                [B, 32-CH, 250, 250]
    nn.ReLU(),                                                 [B, 32-CH, 250, 250]
    nn.Conv2d(32, 32, kernel_size=3, padding=0),               [B, 32-CH, 248, 248]
    nn.BatchNorm2d(32), nn.ReLU(),                             [B, 32-CH, 248, 248]
    nn.MaxPool2d(kernel_size=2, stride=2),                     [B, 32-CH,  124,  124]
)
# 2nd layer
self.layer2 = nn.Sequential(                                   [B, 32-CH, 124,  124]
    nn.Conv2d(32, 64, kernel_size=7, padding=1),               [B, 64-CH, 120, 120]
    nn.BatchNorm2d(64), nn.ReLU(),                             [B, 64-CH, 120, 120]
    nn.Conv2d(64, 64, kernel_size=3, padding=0),               [B, 64-CH,  118,  118]
    nn.BatchNorm2d(64), nn.ReLU(),                             [B, 64-CH,  118,  118]
    nn.MaxPool2d(kernel_size=2, stride=2),                     [B, 64-CH,   59,  59]
)
```

Sériová KinectCNNv2 – štruktúra

```
# 3rd layer
self.layer3 = nn.Sequential(                                    [B,  64-CH, 59, 59]
    nn.Conv2d(64, 128, kernel_size=5, padding=1),               [B, 128-CH, 57, 57]
    nn.BatchNorm2d(128), nn.ReLU(),                             [B, 128-CH, 57, 57]
    nn.Conv2d(128, 128, kernel_size=3, padding=1),              [B, 128-CH, 57, 57]
    nn.BatchNorm2d(128), nn.ReLU(),                             [B, 128-CH, 57, 57]
    nn.MaxPool2d(kernel_size=2, stride=2),                      [B, 128-CH, 28, 28]
)
# 4th layer
self.layer4 = nn.Sequential(                                    [B,  128-CH, 28, 28]
    nn.Conv2d(128, 256, kernel_size=3, padding=1),              [B, 256-CH, 28, 28]
    nn.BatchNorm2d(256), nn.ReLU(),                             [B, 256-CH, 28, 28]
    nn.Conv2d(256, 256, kernel_size=3, padding=1),              [B, 256-CH, 28, 28]
    nn.BatchNorm2d(256), nn.ReLU(),                             [B, 256-CH, 28, 28]
    nn.MaxPool2d(kernel_size=2, stride=2),                      [B, 256-CH,  14,  14]
)
```

Sériová KinectCNNv2 – štruktúra

```
# 5th layer
self.avgpool  = nn.AdaptiveAvgPool2d((1, 1))                [B, 256-CH, 1, 1]

# 6th classifier layer
self.classifier = nn.Sequential(                            [B, 256, 1, 1]
    nn.Flatten(), nn.ReLU(), nn.Dropout(0.3),               [B, 256]

    nn.Linear(in_features=256, out_features=128),           [B, 128]
    nn.ReLU(), nn.Dropout(0.2),                             [B, 128]

    nn.Linear(in_features=128, out_features=64),            [B, 64]
    nn.ReLU(), nn.Dropout(0.1),                             [B, 64]

    nn.Linear(64, num_classes),                             [B, 5]
)
```

Sériová KinectCNNv2 – parametre trénovania

- Trénované na všetkých vrstvách s experimatnálne zvolenými parametrami
  - N_EPOCHS = 150
  - BATCH_SIZE = 8
  - LEARNING_RATE = 0.001
- Trénovacie dáta boli **augmentované** pre dosiahnutie lepšej generalizácie

```
train_transform = transforms.Compose([
    transforms.Resize((256, 256)),
    transforms.RandomHorizontalFlip(),
    transforms.RandomResizedCrop(size=256, scale=(0.9, 1.1)),
    transforms.RandomAffine(degrees=25, translate=(0.1,0.1)),
    transforms.ColorJitter(brightness=0.2, contrast=0.2),
])
```

Sériová KinectCNNv2 – parametre trénovania

- Pri trénovaní bol použitý **SGD optimalizátor** gradientu

```
optimizer = optim.SGD(model.parameters(),
    lr=LEARNING_RATE,
    momentum=0.9,
    weight_decay=1e-4,
    nesterov=True)
```

- Na riadenie rýchlosti učenia bol použitý **CosineAnnealing scheduler**, ktorý postupne znižuje learning rate podľa kosínusovej funkcie

```
scheduler = optim.lr_scheduler.CosineAnnealingLR(
    model.optimizer,
    T_max=N_EPOCHS,
    eta_min=1e-6)
```

Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

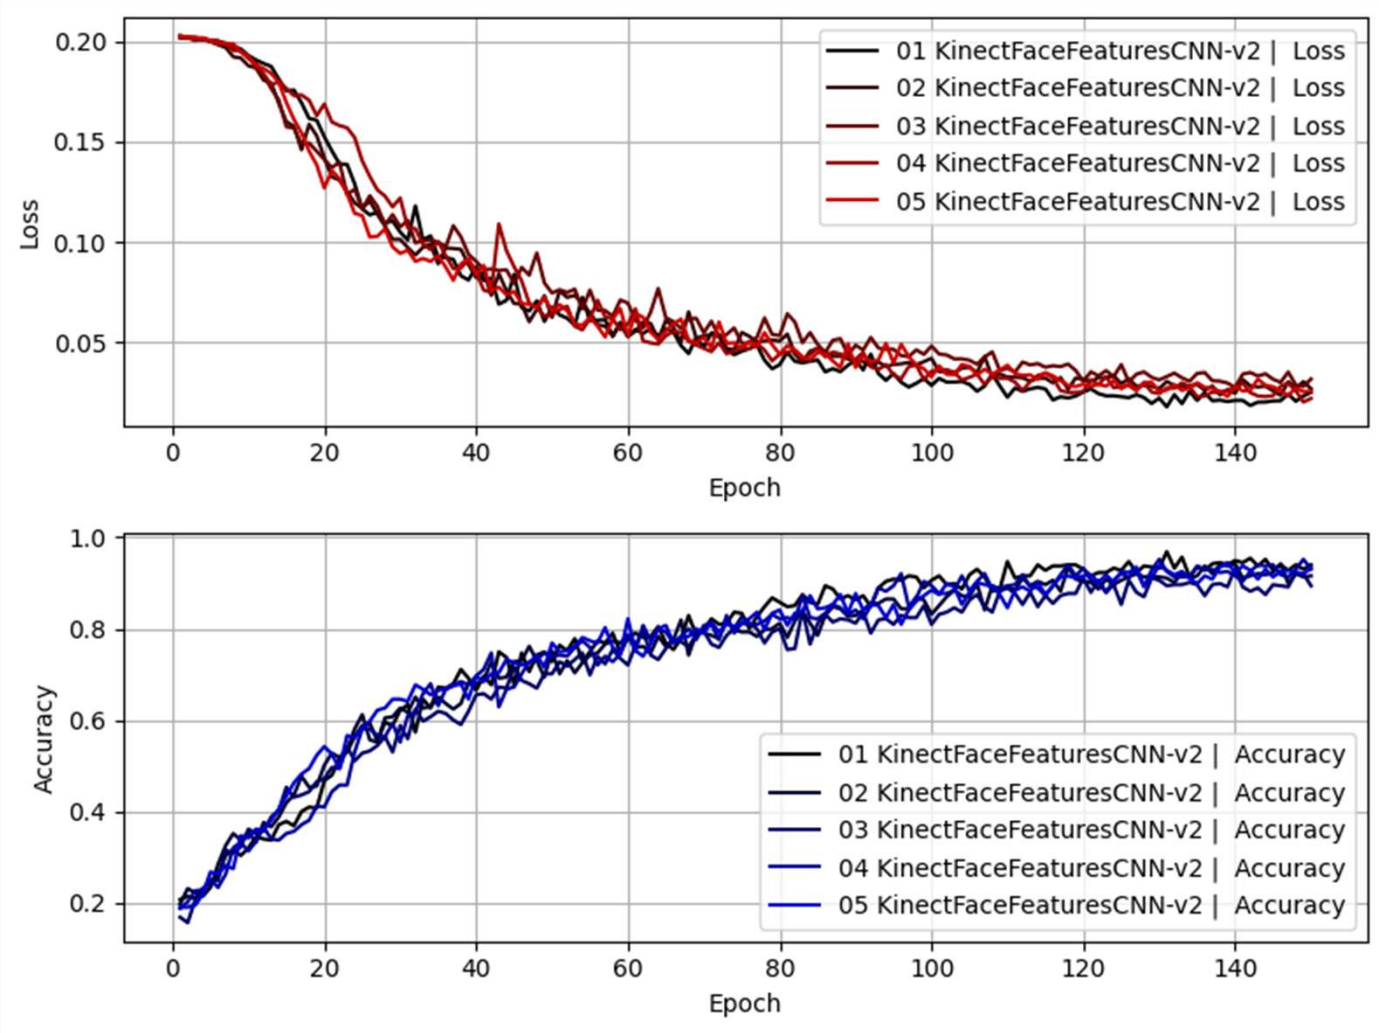
Sériová KinectCNNv2 – úspešnosť

- Úspešnosť klasifikácie vyhodnotená po piatich opakovaniach trénovania s rôznym náhodným rozložením dát bola

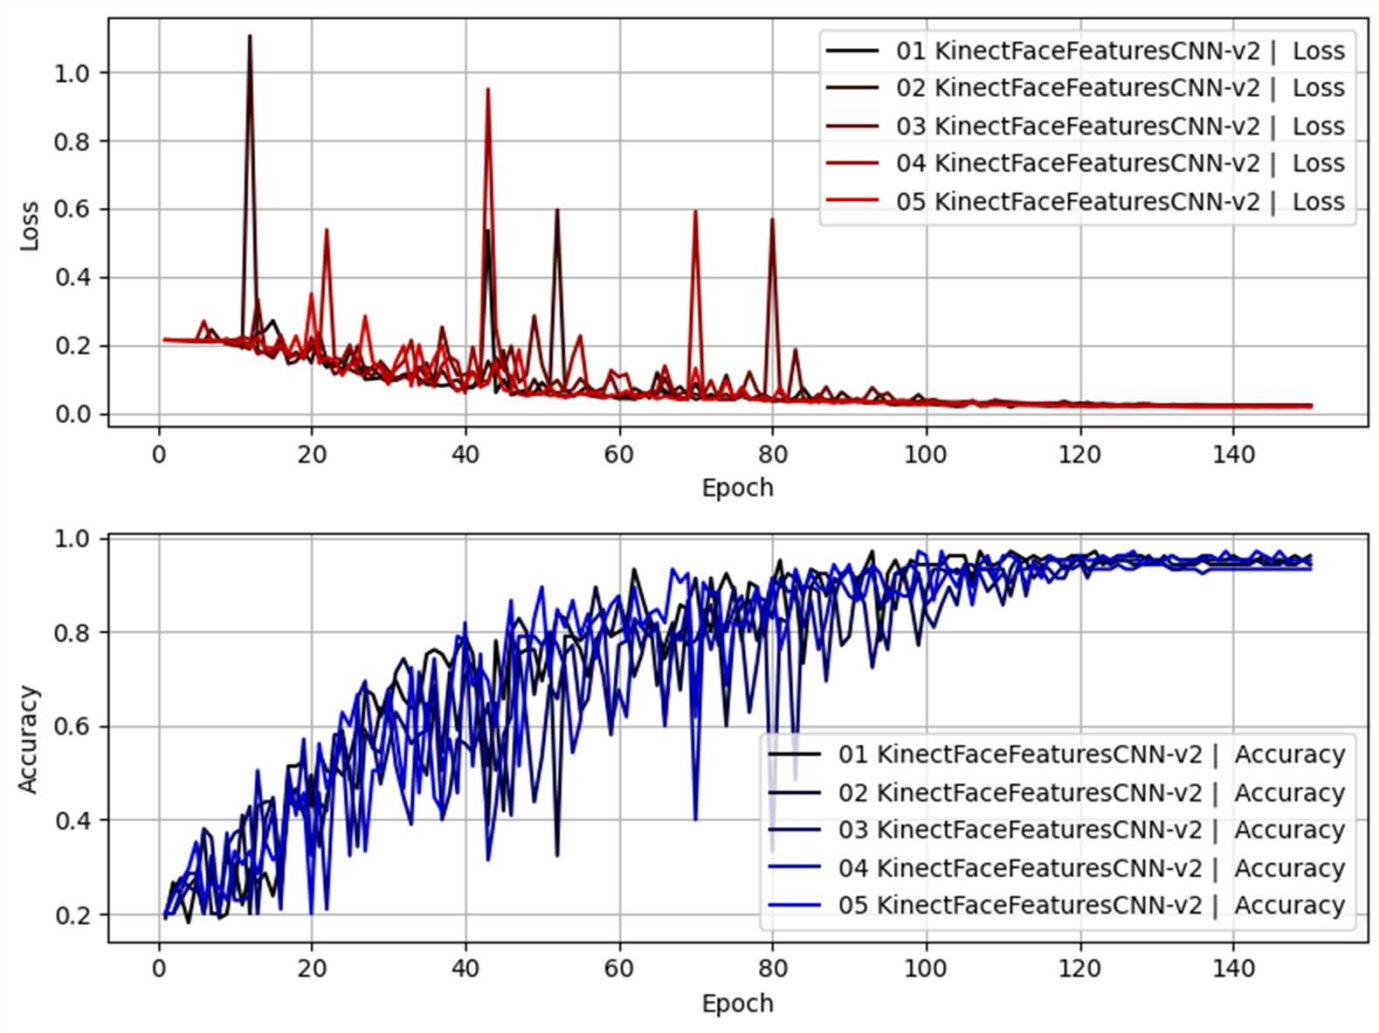
	Priemer	Najlepšia
Trénovacia úspešnosť	92.24%	93.98%
Validačná úspešnosť	94.67%	96.19%
Testovacia úspešnosť		

Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

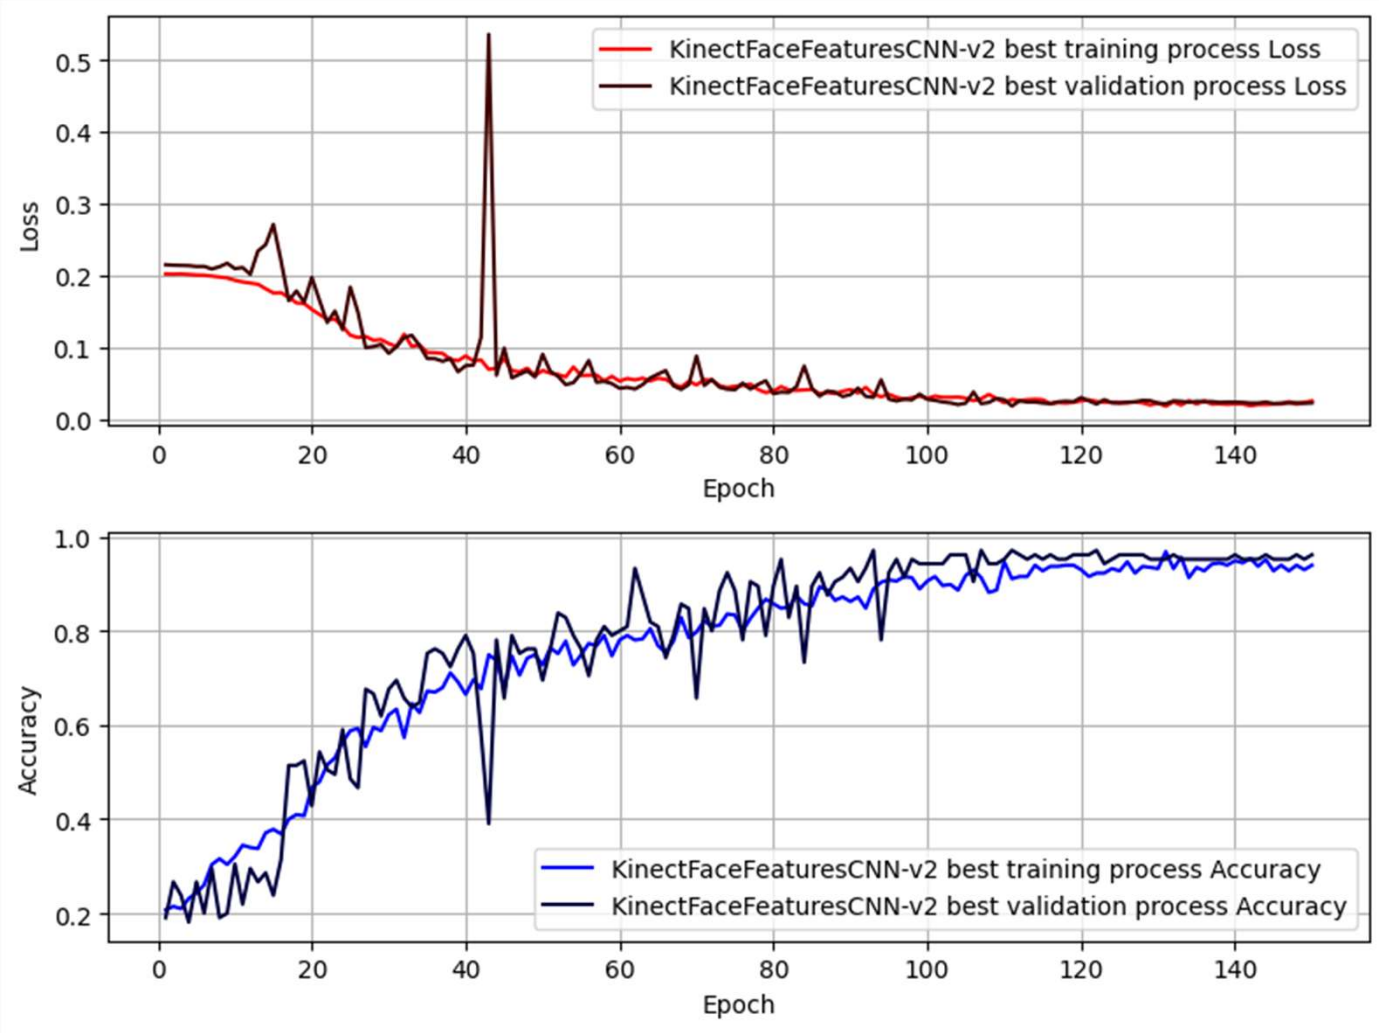
Sériová KinectCNNv2 – trénovací priebeh



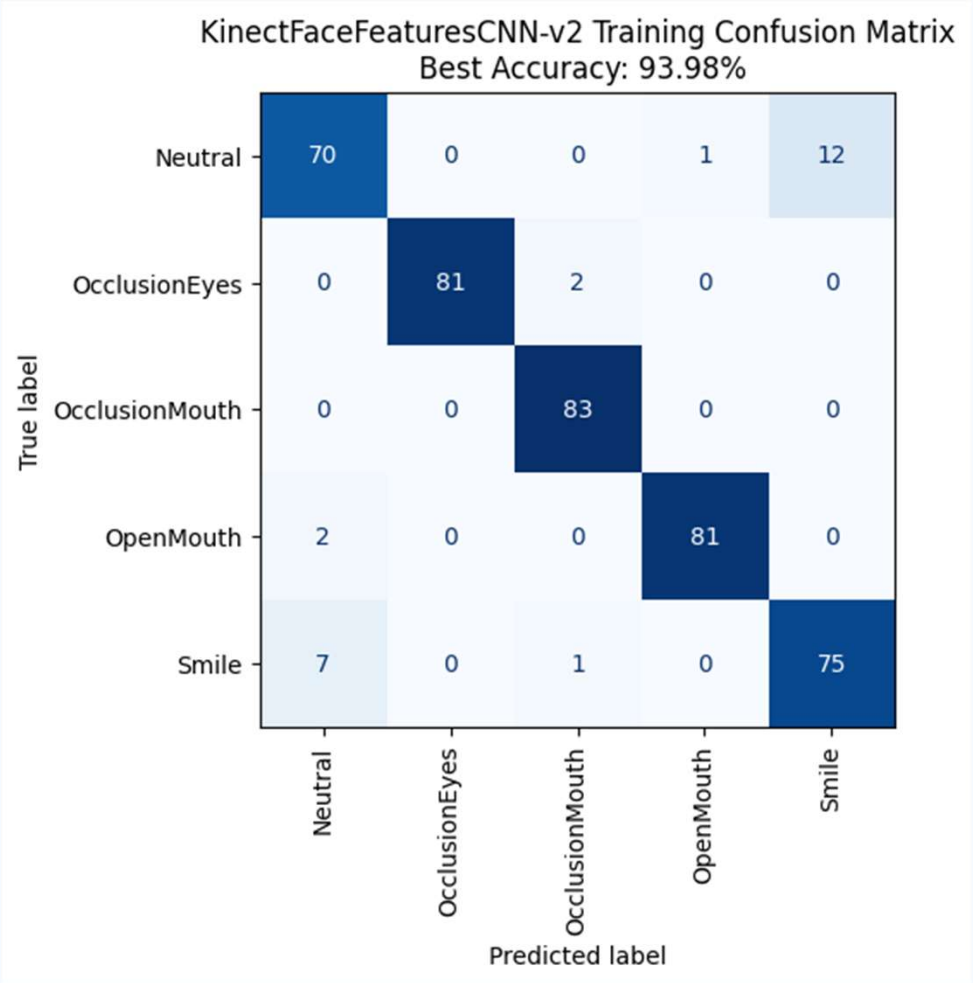
Sériová KinectCNNv2 – validačný priebeh

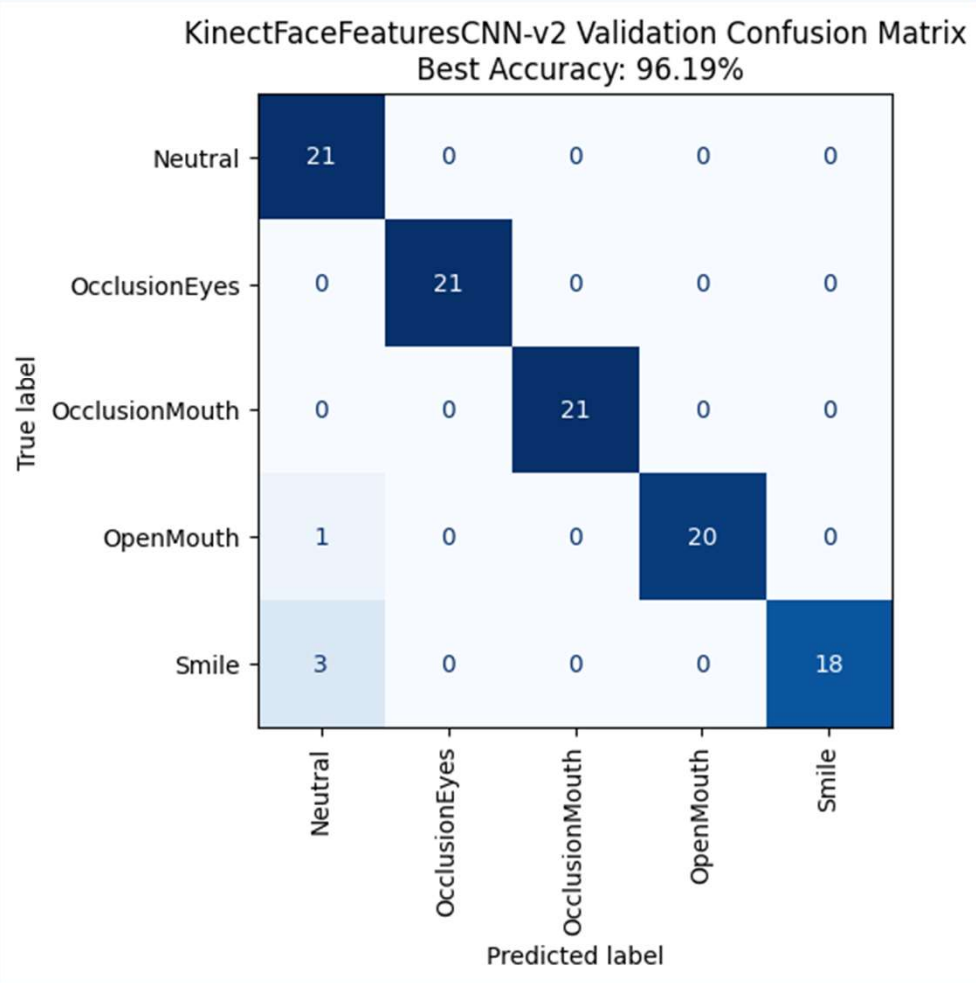


Sériová KinectCNNv2 – najlepšie priebehy



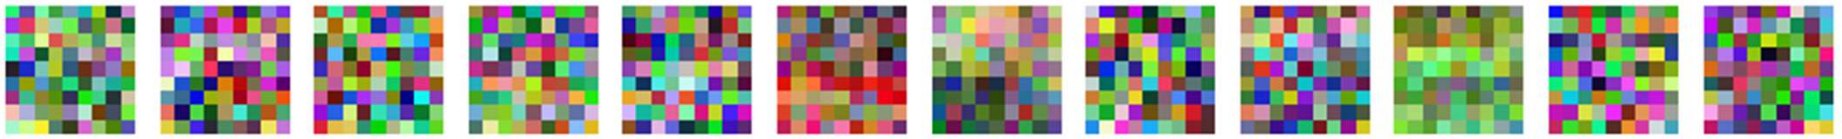
Sériová KinectCNNv2 – kontingenčné tabuľky





Filtre vybraných konvolučných vrstiev

layer1.0 filters



layer2.0 filters



layer4.3 filters



Ústav robotiky a kybernetiky
Fakulta elektrotechniky a informatiky
Slovenská technická univerzita v Bratislave

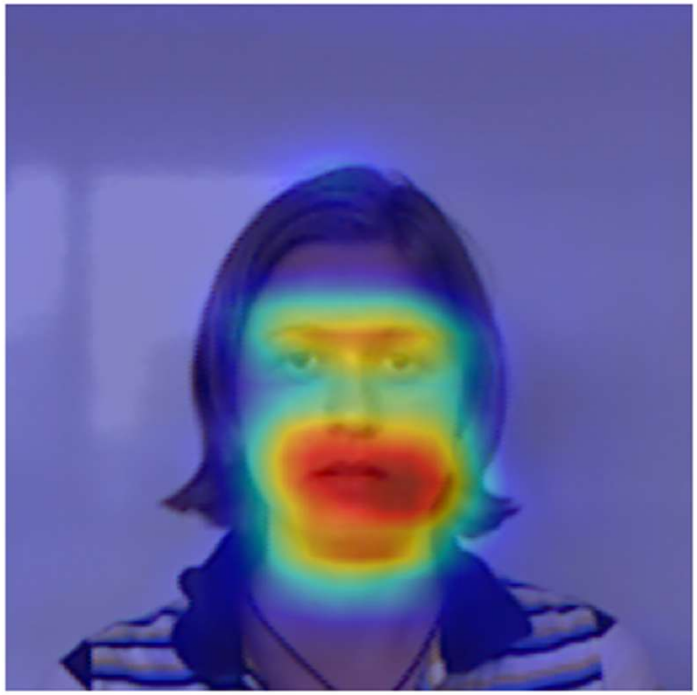


Vizualizácia rozhodovania

EURECOM Kinect Face (RGB)

Vizualizácia rozhodovania – GradCAM++

Sample #13 — Predicted: Neutral — True: Neutral
GradCam++ for 'layer4.3'

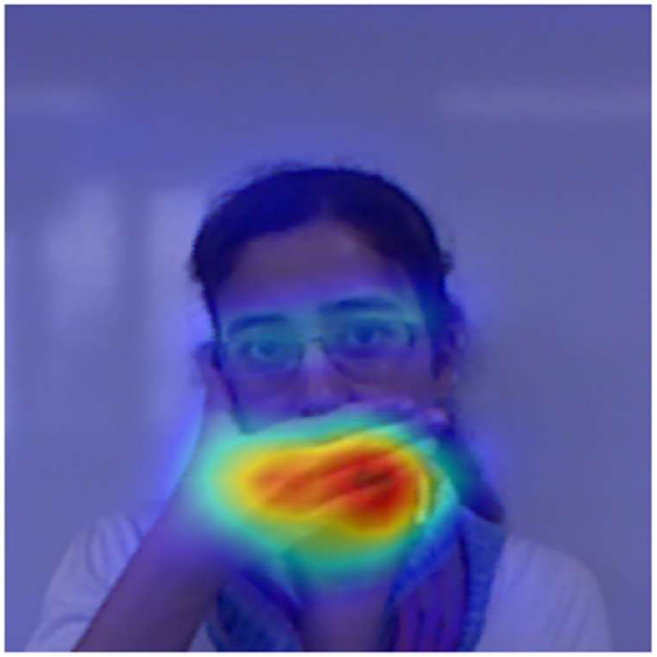


Sample #29 — Predicted: OcclusionEyes — True: OcclusionEyes
GradCam++ for 'layer4.3'

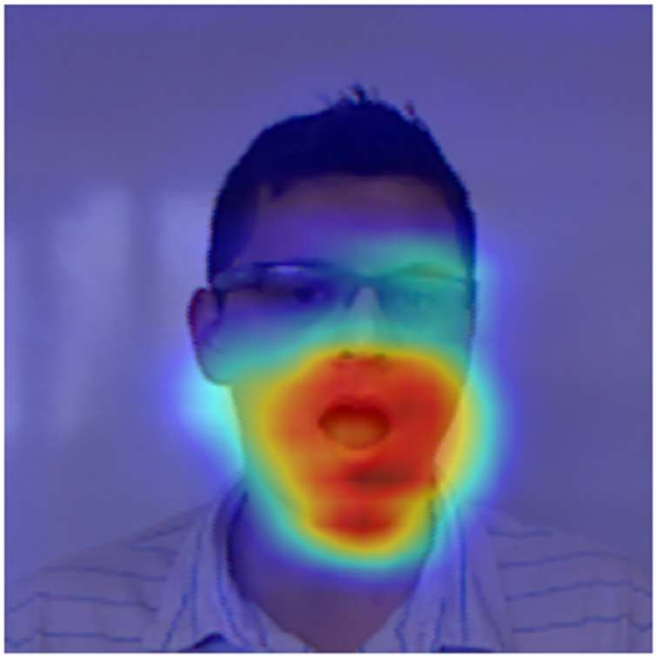


Vizualizácia rozhodovania – GradCAM++

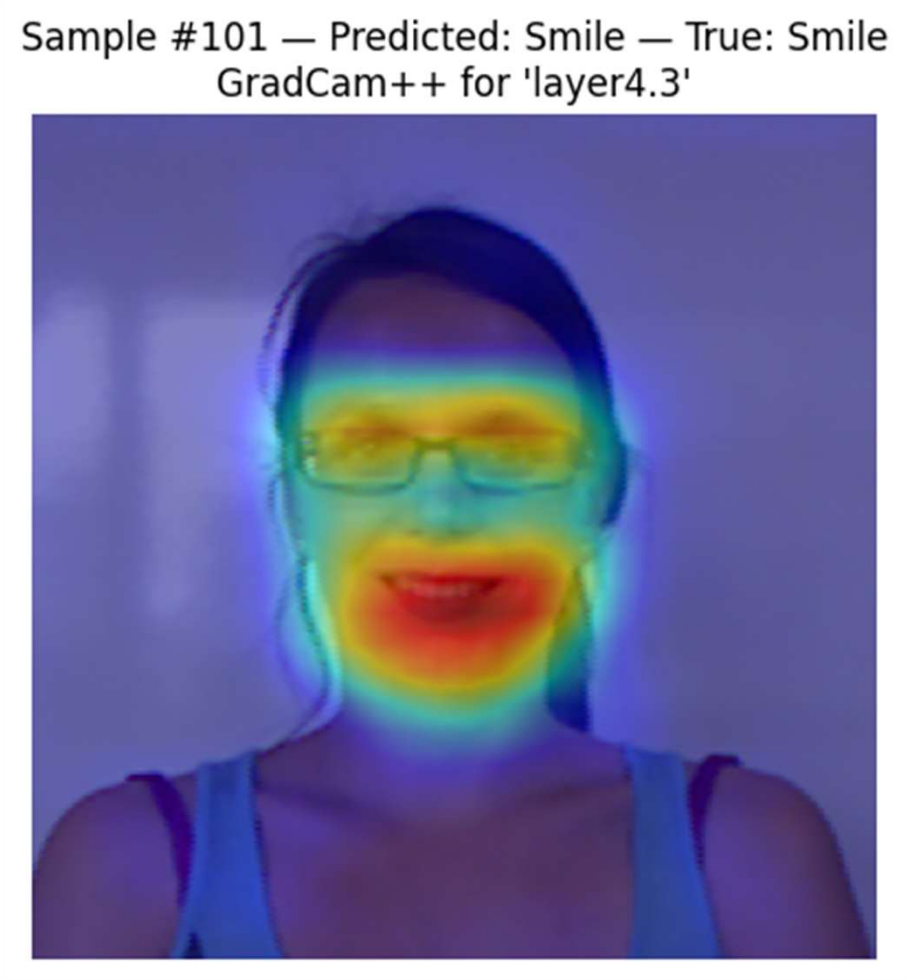
Sample #61 — Predicted: OcclusionMouth — True: OcclusionMouth
GradCam++ for 'layer4.3'



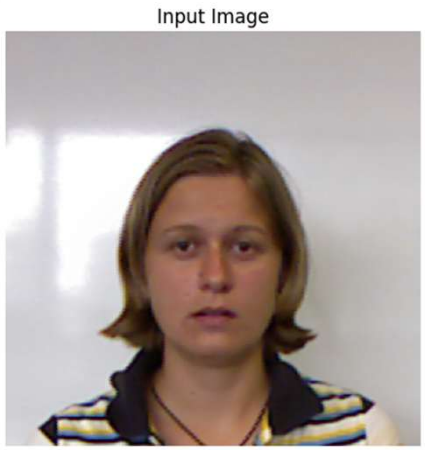
Sample #65 — Predicted: OpenMouth — True: OpenMouth
GradCam++ for 'layer4.3'

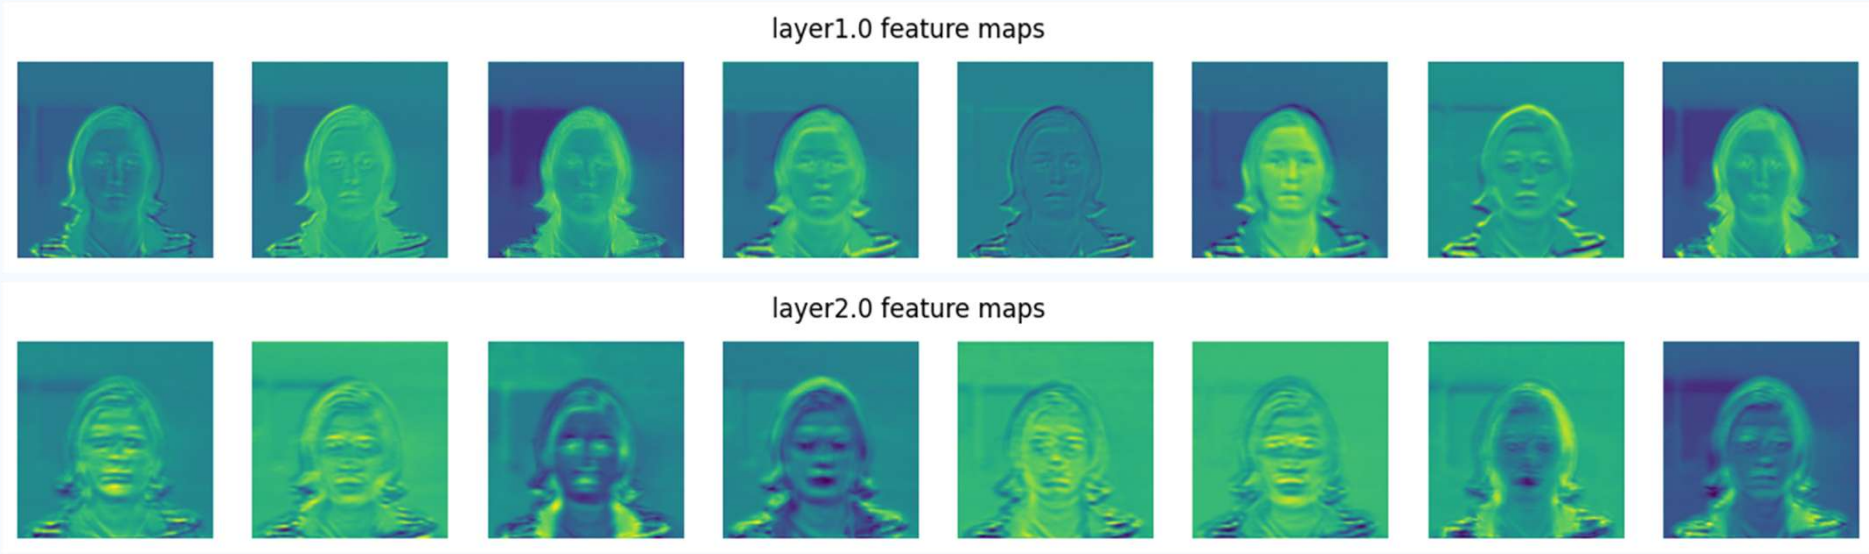


Vizualizácia rozhodovania – GradCAM++

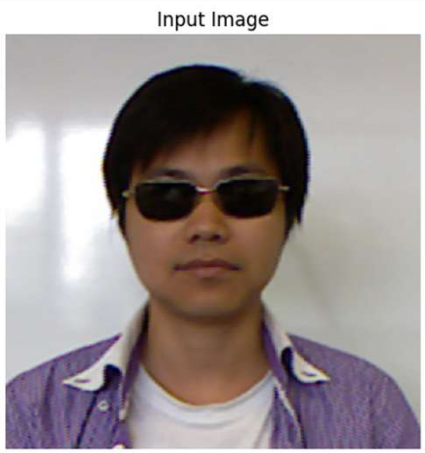


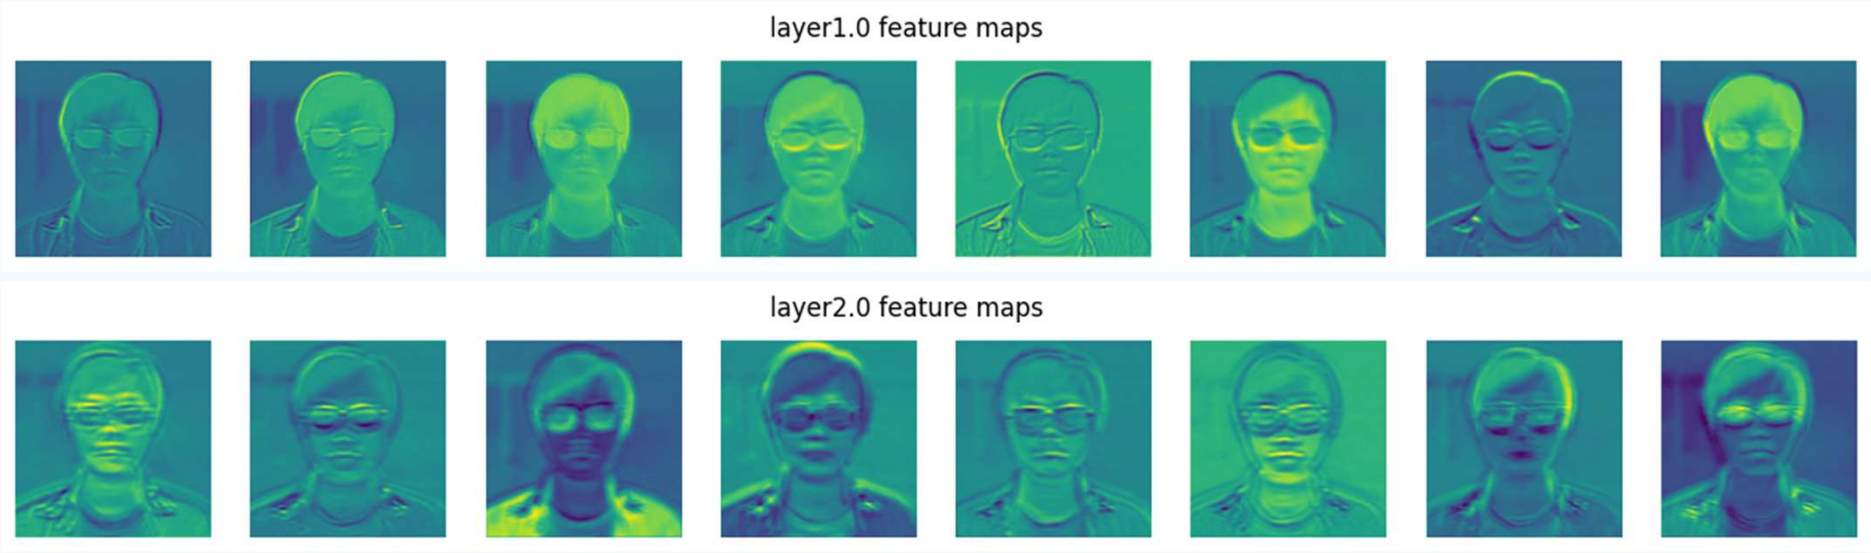
Vybrané mapy príznakov





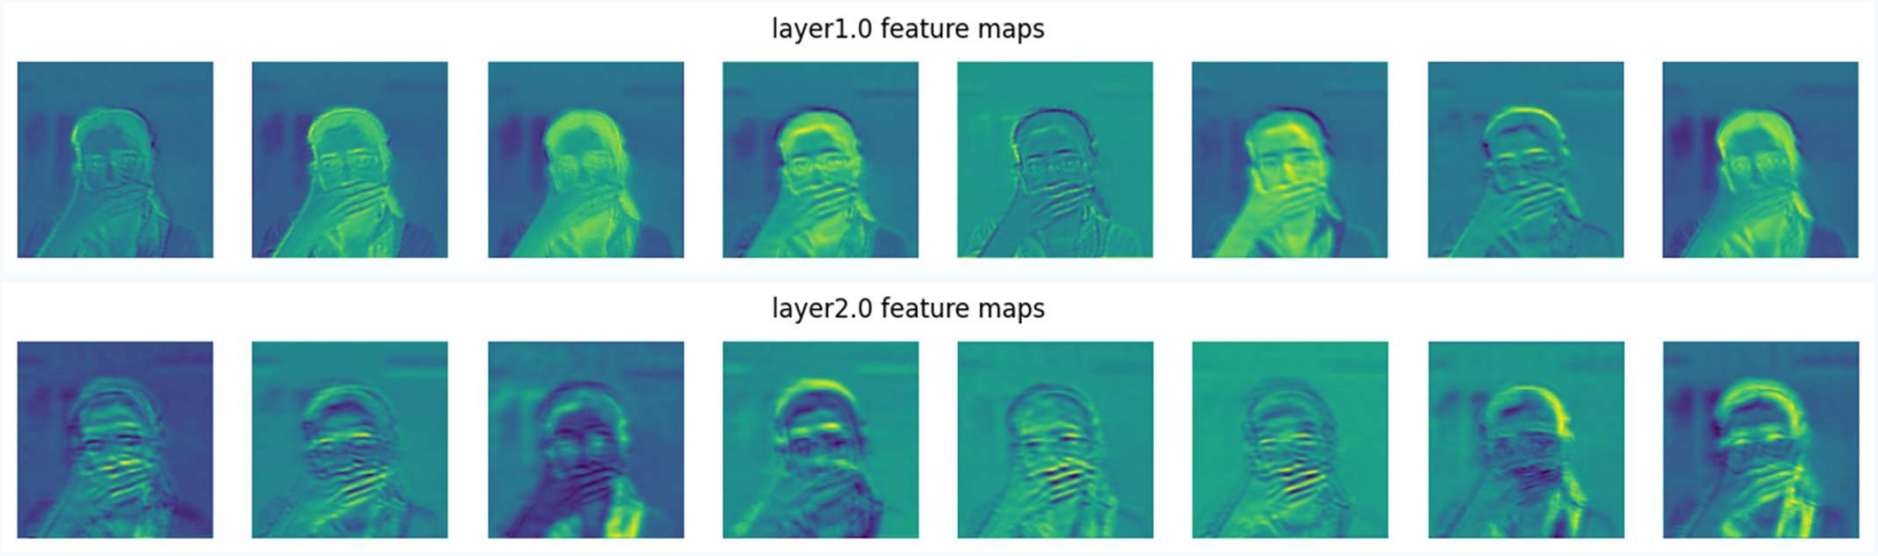
Vybrané mapy príznakov



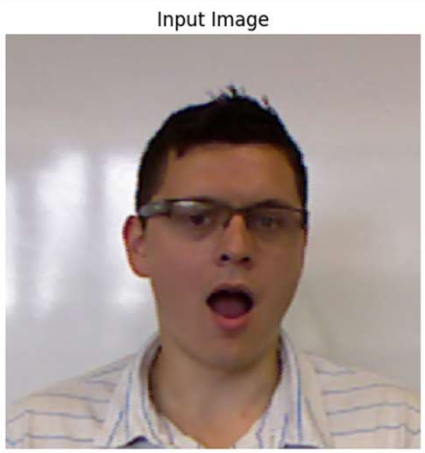


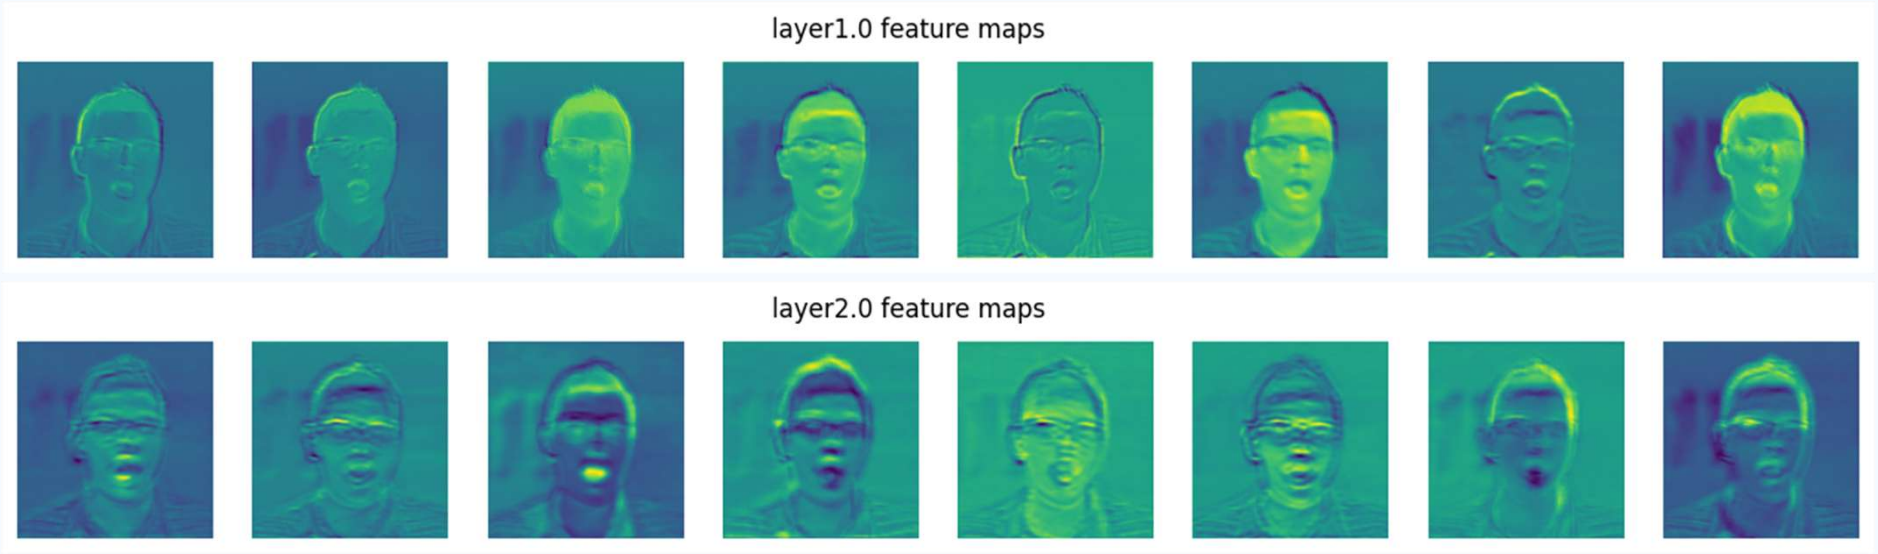
Vybrané mapy príznakov





Vybrané mapy príznakov





Vybrané mapy príznakov



