Spektogram, Mel-spektrogram a MFCC (mel-frequency cepstrum coefficients)

Mel-spektrogram je časovo-frekvenčná reprezentácia zvukového signálu, ktorá ukazuje, **aké frekvencie sa v zvuku vyskytujú a ako sa ich intenzita mení v čase**. Oproti obyčajnému spektrogramu je frekvenčná os upravená podľa **Melovej stupnice**, ktorá približne zodpovedá spôsobu, akým človek vníma rozdiely vo výške tónov.

Pre rozpoznávanie hlasových povelov je veľmi užitočný, pretože z jednorozmerného audio signálu vytvorí v podstate **2D obraz**, ktorý možno dobre spracovať pomocou CNN alebo Transformerov.

1. Východiskom je audio signál

Mikrofón vytvorí časový signál:

$$x[n],\ n = 0{,}1, \dots, N-1$$

Napríklad sekundový záznam pri vzorkovacej frekvencii 16 kHz obsahuje:

$$N = 16000$$

vzoriek. Samotný waveform nám však priamo neukazuje, ktoré frekvencie sa v jednotlivých okamihoch nachádzajú v reči.

2. Premfáza – filtrácia signálu

Filtrácia, ktorá zosilní vyššie frekvencie, vyvažuje frekvenčné spektrum, použitím filtrácie predchádzame numerickým problémom pri FT:

$$y[n] = x[n] - \propto x[n-1],\ n = 1, \dots, N$$

3. Signál sa rozdelí na krátke časové úseky

Reč nie je stacionárny signál – jej frekvenčné vlastnosti sa neustále menia. Preto sa analyzuje po krátkych rámcoch, napríklad:

- dĺžka rámca **25 ms**,
- posun rámca **10 ms**.

Pri 16 kHz teda jeden 25 ms rámec obsahuje:

$$16000 \cdot 0{,}025 = 400$$

vzoriek.

Rámce sa zvyčajne prekrývajú.

4. STFT vytvorí spektrogram

Na každý rámec sa aplikuje Fourierova transformácia. Prakticky sa používa **STFT – Short-Time Fourier Transform**:

$$X(m,k) = \sum_{n} x\,[n] w[n - mH] e^{-j2\pi kn/N}$$

kde m reprezentuje časový rámec a k frekvenčnú zložku.

Z amplitúdy, resp. výkonu:

$$P(m,k) = | X(m,k) |^2$$

dostaneme klasický **spektrogram**.

Ten si môžeme predstaviť ako obraz:

- horizontálna os → **čas**,
- vertikálna os → **frekvencia**,
- jas/hodnota pixelu → **energia signálu**.

5. Frekvencie sa prevedú na Melovu stupnicu

Človek nevníma frekvencie lineárne. Rozdiel medzi 200 a 400 Hz vnímame výraznejšie ako rovnaký rozdiel 5000 a 5200 Hz.

Preto sa používa **Melova stupnica**. Jedna z bežných definícií je:

$$m = 2595 \log_{10}\left(1 + \frac{f}{700}\right)$$

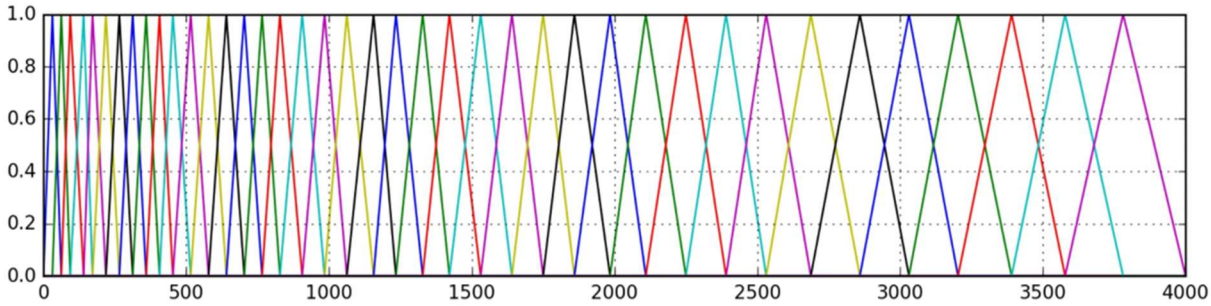
kde f je frekvencia v Hz a m hodnota v meloch.

To spôsobí, že nízke frekvencie sú reprezentované podrobnejšie a vysoké frekvencie hrubšie.

6. Mel filterbank

Na klasický spektrogram sa aplikuje sada trojuholníkových filtrov – **Mel filterbank**.

Schematicky:



Môžeme mať napríklad **40 alebo 64 Mel filtrov**.

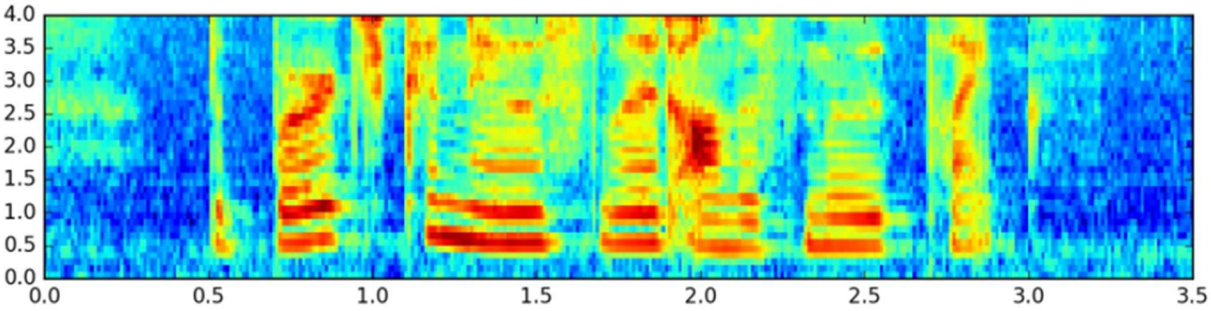
Každý filter spočíta energiu určitého frekvenčného pásma. Namiesto napríklad 257 frekvenčných hodnôt z FFT tak dostaneme iba **40 Mel hodnôt**.

7. Použije sa logaritmus

Ľudské vnímanie hlasitosti je tiež približne logaritmické. Preto sa zvyčajne používa:

$$S_{\text{logMel}} = \log(S_{\text{Mel}} + \epsilon)$$

Výsledkom je **log-Mel spektrogram**. V oblasti hlbokého učenia sa pod označením „Mel-spektrogram“ veľmi často myslí práve táto logaritmická verzia.



Ukážka Mel-spektrogramu

Celý postup

Pre hlasový povel môžeme spracovanie zhrnúť:

mikrofón → waveform → rámcovanie → STFT → výkonové spektrum → Mel filterbank → logaritmus → log-Mel spektrogram

Napríklad sekundový povel pri 16 kHz môže po spracovaní vytvoriť maticu približne:

$$40 \times 100$$

kde máme **40 Mel pásiem × približne 100 časových rámcov**.

Takúto maticu môžeme chápať ako obraz a priviesť ju priamo na vstup CNN:

Mel-spektrogram → CNN → Dense → Softmax → hlasový povel

Mel-spektrogram vs. MFCC

Tieto dve reprezentácie sa často zamieňajú. **MFCC sa v podstate počíta z log-Mel reprezentácie**, na ktorú sa ešte aplikuje DCT:

audio → STFT → Mel filterbank → log → Mel-spektrogram → DCT → MFCC

Pre **hlboké neurónové siete** by som dnes pri rozpoznávaní hlasových povelov vo väčšine prípadov začal s **log-Mel spektrogramom**. Zachováva viac informácií než MFCC a jeho dvojrozmerná časovo-frekvenčná štruktúra je veľmi vhodná pre CNN, CRNN aj Transformery.